HỌC PHẦN 04224 | PHIẾU DỰ ÁN THỰC HÀNH

Dự án ôn tập Tuần 1-2

Dữ liệu mượn sách thư viện

Họ và tên	.....
MSSV	.....
Lớp	.....

Vai trò của bạn
Bạn là chuyên viên phân tích dữ liệu cho thư viện của một trường đại học. Dữ liệu mượn sách năm 2024 được gộp từ ba cơ sở và chứa nhiều vấn đề chất lượng. Hãy xây dựng một quy trình có thể chạy lại để kiểm tra, làm sạch, phân tích và truyền đạt kết quả.

Sản phẩm cần nộp
Một notebook **<mssv>_revision_w1_w2.ipynb** chạy được từ đầu đến cuối và tệp **data/muon_sach_clean.csv**. Không sửa hoặc ghi đè tệp dữ liệu thô bằng Excel.

NỘI DUNG ÔN TẬP

01	**Python, NumPy và Pandas**	Nạp dữ liệu, kiểu dữ liệu, vector hóa, lọc và tổng hợp
02	**Chất lượng dữ liệu**	Trùng lặp, nhãn, ngày, tiền tệ, thiếu và bất thường
03	**Trực quan hóa**	Matplotlib, Seaborn và diễn giải dựa trên bằng chứng

00 Bối cảnh và dữ liệu

Đọc kỹ phần này trước khi mở notebook. Các quy tắc nghiệp vụ là bằng chứng để bạn kiểm tra dữ liệu, không phải đáp án làm sạch sẵn.

Quy định nghiệp vụ

Thời hạn mượn là **14 ngày**. Với phiếu đã trả: **so_ngay_tre = max(0, so_ngay_muon - 14)** và **tien_phat = so_ngay_tre x muc_phat_ngay**. Phiếu chưa trả có thể chưa có ngày trả, số ngày mượn và tiền phạt; đây có thể là trạng thái nghiệp vụ thay vì lỗi.

Cột	Ý nghĩa	Điều cần lưu ý
ma_phieu	Mã phiếu mượn	Mã định danh của lượt mượn
ma_the	Mã thẻ độc giả	Có thể bắt đầu bằng 0; không phải đại lượng số
the_loai	Thể loại sách	Về nghiệp vụ chỉ có 5 thể loại
co_so	Cơ sở thư viện	Về nghiệp vụ chỉ có 3 cơ sở
ngay_muon	Ngày mượn	Dữ liệu thô có nhiều định dạng ngày
ngay_tra	Ngày trả thực tế	Trống nếu sách chưa được trả
so_ngay_muon	Số ngày giữ sách	Bằng ngày trả trừ ngày mượn đối với phiếu đã trả
so_lan_gia_han	Số lần gia hạn	Số nguyên từ 0 trở lên
muc_phat_ngay	Mức phạt mỗi ngày trễ	Đơn vị: đồng/ngày
tien_phat	Tiền phạt	Đơn vị: đồng; có thể ở dạng chuỗi

Nguyên tắc làm bài

Giữ nguyên **df_raw** để so sánh trước/sau. Mọi quyết định làm sạch phải có bằng chứng. Không duyệt từng dòng bằng **for**, **iterrows()** hoặc **apply(axis=1)** ở phần phân tích. Dùng đường dẫn tương đối và lưu bản sạch với tên mới.

A Nạp dữ liệu và lập hồ sơ

Mục tiêu: hiểu bảng trước khi sửa. Trong notebook, mỗi câu phải có code, kết quả và một nhận xét ngắn.

1. Đọc **data/muon_sach_raw.csv** sao cho **ma_phieu** và **ma_the** được giữ như mã định danh. Sau khi đọc, làm thế nào bạn chứng minh các số 0 ở đầu của **ma_the** chưa bị mất?
2. Bảng có bao nhiêu dòng, bao nhiêu cột? Hiển thị các dòng đầu, các dòng cuối và kiểu dữ liệu. Cột nào có kiểu dữ liệu chưa phù hợp với ý nghĩa nghiệp vụ?
3. Viết hàm **profile_dataframe(df)** trả về ít nhất: kiểu dữ liệu, số lượng và tỷ lệ thiếu, số giá trị phân biệt, cùng số dòng trùng hoàn toàn.
4. **ma_phieu** có duy nhất không? Hãy phân biệt ba khái niệm: dòng trùng hoàn toàn, trùng mã nhưng giống nội dung, và trùng mã nhưng mâu thuẫn nội dung. Trường hợp nào có thể xóa tự động?
5. Liệt kê tần số của từng giá trị trong **the_loai** và **co_so**. Có bao nhiêu cách viết trong dữ liệu, và theo nghiệp vụ thực sự có bao nhiêu nhóm?
6. Kiểm tra các mẫu định dạng trong **ngay_muon** và **ngay_tra**. Có mẫu nào không thể là một ngày lịch hợp lệ không? Đừng chuyển đổi dữ liệu trước khi trả lời.
7. Khảo sát miền giá trị của các cột số. Những giá trị nào cần điều tra thêm? Một giá trị nằm ngoài hàng rào IQR có đủ để kết luận nó sai không? Giải thích.
8. Lập bảng kế hoạch làm sạch gồm bốn cột: **vấn đề - bằng chứng - ảnh hưởng - cách xử lý dự kiến**. Không sửa dữ liệu trước khi hoàn thành bảng này.

Điểm dừng A

Bạn phải có một bản mô tả đầy đủ tình trạng dữ liệu trước khi chuyển sang làm sạch. Nếu chỉ gọi **dropna()** hoặc **fillna()** mà chưa giải thích nguyên nhân thiếu, hãy quay lại câu 3-8.

B Làm sạch có kiểm chứng - Phần 1

Mục tiêu: xử lý lỗi định dạng và nhãn mà không làm mất thông tin hợp lệ.

9 Tạo **df_clean** từ **df_raw**. Loại các dòng trùng hoàn toàn. Sau bước này, **ma_phieu** có duy nhất không? Nếu không, hãy điều tra thay vì âm thầm giữ dòng đầu.

10 Chuẩn hóa **the_loai** và **co_so**. Hãy xử lý khoảng trắng, hoa/thường và biến thể mất dấu. Sau bước này phải còn đúng 5 thể loại và 3 cơ sở. Bạn dùng kiểm tra nào để chứng minh điều đó?

11 Chuyển **tien_phat** thành cột số. Một chuỗi như **63.000 đ** có ý nghĩa gì? Vì sao coi dấu chấm là dấu thập phân sẽ tạo sai số nghiêm trọng?

12 Chuyển hai cột ngày sang **datetime**. Hãy nhận diện riêng mẫu **YYYY-MM-DD** và **DD/MM/YYYY**, rồi phân tích mỗi mẫu bằng định dạng tường minh. Vì sao một thiết lập **dayfirst** chung có thể âm thầm đảo tháng/ngày của dữ liệu ISO?

13 Những chuỗi ngày nào trở thành **NaT**? Với ngày mượn không tồn tại, bạn chọn giữ bản ghi hay loại bản ghi? Nêu tác động của quyết định đó đến tổng lượt mượn và biểu đồ theo tháng.

Cảnh báo về ngày
Kết quả chạy không lỗi chưa chắc là kết quả đúng. Sau chuyển đổi, hãy kiểm tra vài ngày có cả ngày và tháng nhỏ hơn hoặc bằng 12 bằng cách đối chiếu chuỗi gốc với giá trị **datetime**.

B Làm sạch có kiểm chứng - Phần 2

Mục tiêu: phân biệt giá trị thiếu mang ý nghĩa nghiệp vụ với lỗi có thể khôi phục chính xác.

14 Tạo mặt nạ cho phiếu **Đã trả** và **Đang mượn**. Vì sao không được điền ngày trả, số ngày mượn hoặc tiền phạt giả cho một phiếu đang mở?

15 Trong các phiếu có đủ hai ngày hợp lệ, tìm các dòng thiếu **so_ngay_muon**. Khôi phục giá trị từ hai cột ngày. Vì sao **fillna(median)** là lựa chọn kém hơn ở đây?

16 Dùng IQR hoặc một phương pháp thống kê khác để tìm ứng viên bất thường trong **so_ngay_muon**. Với mỗi nhóm bất thường, hãy nêu: giả thuyết, bằng chứng kiểm tra và kết luận.

17 Đối chiếu **so_ngay_muon** với **ngay_tra - ngay_muon**. Bạn phân biệt thế nào giữa lỗi gõ số ngày, hai cột ngày bị đảo, và một lượt mượn dài nhưng hợp lệ?

18 Sau khi sửa các lỗi có bằng chứng, kiểm tra mọi phiếu đã trả và có ngày hợp lệ bằng hai ràng buộc:
a) **so_ngay_muon == ngay_tra - ngay_muon**;
b) **tien_phat == max(0, so_ngay_muon - 14) x muc_phat_ngay**.
Nếu còn một dòng lệch, bạn sẽ kiểm tra lại bước nào?

19 So sánh bảng trước và sau làm sạch: kích thước, kiểu dữ liệu, tỷ lệ thiếu, số nhãn phân loại và miền giá trị. Thay đổi nào là chủ ý? Thay đổi nào sẽ là dấu hiệu bạn đã làm mất dữ liệu?

20 Lưu bảng đã làm sạch thành **data/muon_sach_clean.csv**. Đọc lại chính tệp vừa lưu và chạy các kiểm tra quan trọng một lần nữa. Vì sao kiểm tra DataFrame trong bộ nhớ thôi là chưa đủ?

Điểm dừng B
Chỉ chuyển sang phân tích khi mọi phiếu đã trả và có ngày hợp lệ vượt qua cả hai kiểm chứng chéo. Phiếu đang mượn vẫn được phép có giá trị thiếu mang ý nghĩa nghiệp vụ.

C Tạo biến và phân tích NumPy/Pandas

Tạo các cột so_ngay_tre, trang_thai và thang_muon trước khi trả lời. Ưu tiên thao tác vector hóa.

21 Tạo **so_ngay_tre = max(0, so_ngay_muon - 14)**, **trang_thai** gồm Đã trả/Đang mượn và **thang_muon** từ ngày mượn hợp lệ. Kiểm tra miền giá trị của từng biến mới.

22 Thể loại nào có số lượt mượn nhiều nhất? Báo cáo cả số lượng và tỷ trọng. Kết quả có thay đổi nếu loại các dòng không có ngày mượn hợp lệ không?

23 Với các phiếu đã trả và hợp lệ, tính trung vị và khoảng tứ phân vị của **so_ngay_muon** theo thể loại. Vì sao trung vị có thể phù hợp hơn trung bình cho câu hỏi này?

24 Cơ sở nào có tỷ lệ phiếu Đang mượn cao nhất? Hãy dùng tỷ lệ trên tổng phiếu của từng cơ sở, không chỉ so sánh số lượng tuyệt đối.

25 Số lần gia hạn liên hệ thế nào với thời gian mượn? Trình bày một bảng tổng hợp theo **so_lan_gia_han** và một hệ số tương quan phù hợp. Tương quan có chứng minh quan hệ nhân quả không?

26 So sánh tổng tiền phạt và tiền phạt trung bình trên mỗi phiếu đã trả giữa các thể loại. Hai thước đo có dẫn đến cùng một thứ hạng không? Nếu khác, giải thích vì sao.

27 Đếm lượt mượn theo tháng. Các bản ghi có ngày mượn không hợp lệ được xử lý thế nào trong phép tổng hợp, và giới hạn này phải được ghi ở đâu trong báo cáo?

28 Chọn ít nhất một câu trên, chuyển các cột cần thiết thành mảng NumPy và giải bằng phép toán vector hóa, mặt nạ boolean hoặc hàm thống kê NumPy. So sánh với kết quả Pandas tương ứng.

Yêu cầu kỹ thuật

Không dùng vòng lặp theo từng dòng. Nếu dùng vòng lặp để duyệt qua một danh sách nhỏ các tên cột hoặc để bố trí biểu đồ, hãy giải thích rõ; điều cấm là thay thế phép toán vector hóa bằng xử lý từng bản ghi.

D Trực quan hóa và diễn giải

Dùng cả Matplotlib và Seaborn. Mỗi biểu đồ phải giúp người đọc trả lời một câu hỏi cụ thể.

29 Vẽ biểu đồ cột số lượt mượn theo thể loại. Sắp xếp các cột theo cách giúp so sánh nhanh. Viết 1-2 câu nêu phát hiện, không chỉ mô tả cột cao/thấp.

30 Vẽ box plot **so_ngay_muon** theo thể loại, chỉ dùng phiếu đã trả và hợp lệ. Những điểm nằm ngoài râu hộp có tự động là lỗi dữ liệu không?

31 Vẽ biểu đồ đường số lượt mượn theo tháng. Bảo đảm trục thời gian đúng thứ tự và hiển thị đủ các tháng, kể cả tháng có ít lượt mượn.

32 Vẽ biểu đồ tỷ lệ phiếu Đang mượn theo cơ sở. Vì sao biểu đồ tỷ lệ trả lời câu hỏi công bằng hơn biểu đồ số lượng tuyệt đối?

33 Với mỗi biểu đồ, bổ sung tiêu đề, nhãn trục, đơn vị, thứ tự nhóm và màu sắc phù hợp. Nêu một giới hạn do dữ liệu thiếu hoặc quyết định làm sạch có thể ảnh hưởng đến cách đọc biểu đồ.

E Kết luận và đề xuất

Viết 150-250 từ. Mọi nhận định quan trọng phải truy ngược được về một bảng hoặc biểu đồ trong notebook.

34 Hai phát hiện quan trọng nhất về hoạt động mượn sách là gì? Với mỗi phát hiện, dẫn ít nhất một con số cụ thể.

35 Vấn đề chất lượng dữ liệu nào nguy hiểm nhất nếu bị bỏ qua? Nó sẽ làm sai chỉ số hoặc kết luận nào?

36 Đề xuất một hành động cụ thể cho quản lý thư viện. Giải thích bằng bằng chứng từ phân tích và tránh suy diễn vượt quá dữ liệu.

□ Tự kiểm tra trước khi nộp

Đánh dấu từng mục sau khi Restart Kernel and Run All Cells thành công.

□ **ma_the** vẫn giữ đủ 4 ký tự, kể cả số 0 ở đầu.

□ **df_raw** được giữ nguyên để so sánh; tệp dữ liệu thô không bị ghi đè.

□ Sau khi loại dòng trùng hoàn toàn, **ma_phieu** là duy nhất hoặc mọi xung đột còn lại đã được giải thích.

□ Chỉ còn 5 thể loại và 3 cơ sở chuẩn.

□ Cột ngày có kiểu datetime; cột tiền và số ngày có kiểu số phù hợp.

□ Phiếu Đang mượn không bị gán ngày trả hoặc tiền phạt giả.

□ Mọi phiếu đã trả và có ngày hợp lệ vượt qua hai kiểm chứng chéo.

□ Phân tích chính dùng thao tác vector hóa, không duyệt từng dòng.

□ Có ít nhất một phép phân tích bằng NumPy và kết quả được đối chiếu với Pandas.

□ Có đủ bốn biểu đồ, dùng cả Matplotlib và Seaborn.

□ Mỗi biểu đồ có tiêu đề, nhãn, đơn vị, nhận xét và giới hạn khi cần.

□ Notebook dùng đường dẫn tương đối và tạo được **data/muon_sach_clean.csv**.

□ Notebook chạy hoàn chỉnh sau Restart Kernel and Run All Cells.

Tệp 1	<mssv>_revision_w1_w2.ipynb
Tệp 2	data/muon_sach_clean.csv

Tiêu chí của một bài làm tốt

Không chỉ cho ra con số đúng, bài làm phải cho thấy bạn hiểu dữ liệu, có lý do cho mỗi quyết định, kiểm tra độc lập sau biến đổi và truyền đạt kết quả để người đọc có thể hành động.